인공지능 실습 Chapter 5. Adversarial Search

포항공과대학교 컴퓨터공학과



목치

- 5.1. Adversarial Search 개요
- 5.2. Minimax & Expectimax Algorithm
- 5.3. Pruning
- 5.4. Imperfect Real-time Decisions
- 5.5. Multi-player Game


5.1. Adversarial Search 개요

Tic-tac-toe


- 두 명의 player: X(선수) and O(후수)
- 맵: 3 x 3 grid
- 승리조건: 연속된 세 칸에 본인의 돌을 놓으면 승리
- 맵에 빈 자리가 없는데도 승패가 결정이 나지 않으면 비김

구글에서 "tic tac toe" 검색 or

https://playtictactoe.org/




Tic-tac-toe



• 미래의 상대방의 action을 고려해 본인의 action을 결정해야 함

Tic-tac-toe Game Tree



Adversarial Search의 특징


- Deterministic action (v.s. MDP)
- Fully observable environment (v.s. POMDP)
- Zero-sum at the end (v.s. typical search, MDP)
 - 각 플레이어의 utility는 서로 동일하거나 반대
 - 중간 action에 대한 utility는 정의되지 않음
 - Chess의 목표는 많은 말을 잡는 것이 아닌 체크메이트(King)를 하는 것이 목적
 - Typical search 및 MDP에 비해 어려운 부분
- Turn-taking of players
 - Typical search에서는 goal state에 도달하기 위한 action sequence를 찾으면 됨
 - Opponent가 agent의 action에 맞춰 대응하므로 action sequence가 아닌 policy를 찾아야 함

Policy

- Deterministic policy: $\pi_p(s) = Action(s)$
 - action that player p takes in state s
- Stochastic policy: $\pi_p(s, a) \in [0, 1]$
 - probability of player p taking action a in state s

AI Challenges

IBM DeepBlue (Chess) – 1996



Google AlphaGo – 2016



- 사람과의 대결을 통해 AI 기술수준을 보여 준 사례
- 학습의 명확한 기준(승패)이 존재

Adversarial Search의 요소

- *S*_{start}: 시작 상태
- Actions(s): s에서 취할 수 있는 모든 action
- Cost(s,a): s에서 a를 취하는 cost(비용)
- Succ(s,a): s에서 a를 취했을 때 다음 상태
- IsEnd(s): s의 종료 조건 만족 여부
- Utility(s): 종료 상태 s에서 agent의 utility
- Player(s): s에서 action을 취할 수 있는 player

Players = {agent (your program); opp (opponent)

MAX MIN


e.g. 알파고

e.g. 이세돌

Simple Game

• Agent 및 opponent가 차례로 1회씩 action을 선택하는 게임


• 상대방의 선택을 알 수 없음



5.2. Minimax & Expectimax Algorithm

Minimax Algorithm 예

- **최악의 경우**를 가정
 - Opponent는 value를 낮추는 선택을 한다



Minimax Algorithm

Minimax policy

$$\pi_{\max}(s) = \underset{a \in Action(s)}{\arg \max} V_{\max,\min}(Succ(s, a))$$

$$\pi_{\min}(s) = \underset{a \in Action(s)}{\arg \min} V_{\max,\min}(Succ(s, a))$$

Value function for minimax

$$V_{\max,\min}(s) = \begin{cases} \text{Utility}(s) & \text{IsEnd}(s) \\ \max_{a \in \text{Actions}(s)} V_{\max,\min}(\text{Succ}(s,a)) & \text{Player}(s) = \text{agent} \\ \min_{a \in \text{Actions}(s)} V_{\max,\min}(\text{Succ}(s,a)) & \text{Player}(s) = \text{opp} \end{cases}$$


Minimax Algorithm Pseudocode

```
def V(state)
    if is end(state):
        return utility(state)
    if is_maxi_player(state):
        value = -∞
        for action in actions(state):
            value = max(value, V(next_state(state, action)))
    else:
        value = ∞
        for action in actions(state):
            value = min(value, V(next state(state, action)))
    return value
```

```
def policy(state)
...
```

Minimax Algorithm 구현

- Simple Game을 대상으로 구현
 - 상태를 (플레이어, 상태 심볼)로 표현
 - 예. ('MIN', 'C')
- simple_game/game.py
 - INT_INF = 10000000000000
 - MAX_PLAYER = 'MAX'
 - MIN_PLAYER = 'MIN'
 - is_end(state)
 - utility(state)
 - get_initial_state()
 - get_next_state(state, action)
 - get_next_player(player)
 - get_possible_actions(state)
 - get_player_from_state(state)




Minimax Algorithm 구현

- simple_game/play.py
 - 실행 방법: play.py minimax
 - 두 상태에서의 value 및 action 확인
 - ('MAX', 'A')
 - ('MIN', 'B')

- simple_game/ai.py
 - MinimaxAgent 클래스의 V 및 policy 함수 구현
 - V(state): 해당 state에서의 value 값 리턴
 - policy(state): policy를 따라 해당 state에서의 action 결정

Expectimax Algorithm 예

• 상대의 **random한 선택**을 가정



Expectimax Algorithm

Expectimax policy

$$\pi_{\max}(s) = \underset{a \in Action(s)}{\operatorname{arg max}} V_{\max, \text{opp}}(\operatorname{Succ}(s, a))$$

$$\pi_{\operatorname{opp}}(s, a) = \frac{1}{|\operatorname{Action}(s)|} \text{ for } a \in \operatorname{Actions}(s)$$

Value function for expectimax

$$V_{\max, \text{opp}}(s) = \begin{cases} \text{Utility}(s) & \text{IsEnd}(s) \\ \max_{a \in \text{Actions}(s)} V_{\max, \min}(\text{Succ}(s, a)) & \text{Player}(s) = \text{agent} \\ \sum_{a \in \text{Actions}(s)} \pi_{\text{opp}}(s, a) V_{\max, \text{opp}}(\text{Succ}(s, a)) & \text{Player}(s) = \text{opp} \end{cases}$$

Expectimax Algorithm Pseudocode

```
def V(state)
    if is end(state):
        return utility(state)
    if is_maxi_player(state):
        value = -∞
        for action in actions(state):
            value = max(value, V(next state(state, action)))
    else:
        value = 0
        for action in actions(state):
            value += V(next state(state, action)) / actions(state)
    return value
```

```
# Policy에 따라 결정한 action을 반환
def policy(state)
...
```

Expectimax Algorithm 구현


- simple_game/play.py
 - 실행 방법: play.py expectimax
 - 두 상태에서의 value 및 action 확인
 - ('MAX', 'A')
 - ('MIN', 'B')

- simple_game/ai.py
 - ExpectimaxAgent 클래스의 V 및 policy 함수 구현
 - V(state): 해당 state에서의 value 값 리턴
 - policy(state): policy를 따라 해당 state에서의 action 결정

5.3. Pruning


Pruning 예

• d₂는 고려하지 않아도 A에서의 선택은 바뀌지 않음




Alpha-beta Pruning

- Search tree에서 최종 결정에 영향을 안 주는 부분은 무시함으로써 속도 향상
- α : lower bound on value of **max** node s
 - i.e. maximum value found so far
 - Initial $\alpha = -\infty$
 - $\alpha = \max(\alpha, \text{ value})$
- β : upper bound on value of **min** mode s
 - i.e. minimum value found so far
 - Initial $\beta = \infty$
 - $\beta = \min(\beta, \text{ value})$
- Pruning: $\beta \leq \alpha$ 가 되면 해당 부분 search 중단



Alpha-beta Pruning 적용 예



Alpha-beta Pruning Pseudocode

```
def V(state, \alpha, \beta)
    if is_end(state):
         return utility(state)
    if is maxi player(state):
         value = -∞
         for action in actions(state):
              value = max(value, V(next_state(state, action), α, β)
              \alpha = \max(\alpha, \text{ value})
              if \beta \leq \alpha: break
    else:
         value = ∞
         for action in actions(state):
              value = min(value, V(next_state(state, action), α, β)
              \beta = \min(\beta, \text{ value})
              if \beta \leq \alpha: break
    return value
```

Alpha-beta Pruning 구현

- simple_game/play.py
 - 실행 방법: play.py pruning
 - 두 상태에서의 value 및 action 확인
 - ('MAX', 'A')
 - ('MIN', 'B')
 - V 함수 호출 회수 minimax와 비교

- simple_game/ai.py
 - PruningMinimaxAgent 클래스의 V 및 policy 함수 구현
 - V(state): 해당 state에서의 value 값 리턴
 - policy(state): policy를 따라 해당 state에서의 action 결정

Tic-tac-toe 구현

1	2	3
4	5	6
7	8	9

- Dictionary 형태의 상태표현
 - state['PLAYER']: player 저장
 - state[1]: 위치 1에 놓인 돌 ∈ ['X', 'O', '']
 - ...
 - state[9]: 위치 9에 놓인 돌 ∈ ['X', 'O', '']

Tic-tac-toe 구현

- tic_tac_toe/game.py: Tic-tac-toe 게임 관련 유틸리티
- tic_tac_toe/ai.py
 - simple_game의 AI 코드를 그대로 복사
- tic_tac_toe/play.py: AI와 Tic-tac-toe 게임 플레이
 - play.py minimax
 - play.py pruning

• AI의 quality 확인

- Minimax와 alpha-beta pruning의 탐색 시간 비교
 - Minimax는 AI가 선플레이어인 경우 굉장히 느림

Tic-tac-toe 구현

Tic-tac-toe 최선의 전략

선수: 모서리나 중앙으로 공격


후수:

- 상대방이 모서리에 둔 경우 중앙으로 방어
- 상대방이 중앙에 둔 경우 모서리로 방어

- 플레이를 통해 AI가 위 전략을 구사하는지 확인
- 개발자가 이러한 전략을 모르더라도 최선의 전략을 구사하는 AI를 구현 할 수 있다
 - 규칙(전문가) v.s. 계산 및 데이터

5.4. Imperfect Real-time Decisions

Imperfect Real-time Decisions





Tic-tac-toe

• Search tree 최대 노드 = 9!

Chess

- 평균 action 수 = 35
- 평균 턴 수 = 50
- Search tree 평균 노드 수 = 35¹⁰⁰

복잡한 문제에서는 트리의 leaf를 보고 action을 결정하는 것이 불가능!



Imperfect real-time decisions

Depth-limited Search

Value function for depth-limited search

$$V_{\max,\min}(s, \mathbf{d}) = \begin{cases} \mathsf{Utility}(s) & \mathsf{IsEnd}(s) \\ \mathsf{Eval}(s) & \mathbf{d} = 0 \\ \max_{a \in \mathsf{Actions}(s)} V_{\max,\min}(\mathsf{Succ}(s, a), \mathbf{d}) & \mathsf{Player}(s) = \mathsf{agent} \\ \min_{a \in \mathsf{Actions}(s)} V_{\max,\min}(\mathsf{Succ}(s, a), \mathbf{d} - 1) & \mathsf{Player}(s) = \mathsf{opp} \end{cases}$$

- Evaluation function Eval(s)
 - V_{max,min}(s)에 대한 추정(estimation)값
 - Search 문제에서의 FutureCost(s)와 유사한 개념

• Use: at state s, call $V_{\text{max,min}}(s, d_{\text{max}})$


Evaluation Function 예. Chess



Chess pieces

- **§** King (∞)
- **Q**ueen (9)
- **Rook** (5)
- **Bishop** (3)
- Knight (3)
- **A** Pawn (1)
- Eval(s) = material + mobility + king-safety + center-control
 - material = $10^{100}(K K') + 9(Q Q') + 5(R R')$ +3(B - B' + N - N') + 1(P - P')
 - mobility = 0.1 (num-legal-moves num-legal-moves')
- 체스에서는 이러한 hand-tuned evaluation function이 잘 작동함

Evaluation Function for Tic-tac-toe



Heuristic array


MAX	MIN			
	0	1	2	3
0	0	-10	-100	-1000
1	10	0	0	0
2	100	0	0	0
3	1000	0	0	0

```
def eval(state):
    value = 0
    for 승리조건 of board:
        maxs = 승리조건에 놓여있는 MAX의 돌 수
        mins = 승리조건에 놓여있는 MIN의 돌 수
        value += heuristic[maxs][mins]
    return value
```

https://kartikkukreja.wordpress.com/2013/03/30/heuristic-function-for-tic-tac-toe/

Evaluation Function for Tic-tac-toe

• Agent가 후수(O)



Agent는 O를 중앙(5)에 배치

Tic-tac-toe 구현 (Alpha Tic-tac-toe!)


- tic_tac_toe/game.py: Tic-tac-toe 게임 관련 유틸리티
- tic_tac_toe/ai.py: DepthLimitedMinimaxAgent 구현
 - Minimax를 복사해 수정
 - 위 evaluation function을 구현한 eval(s) 사용
- tic_tac_toe/play.py: AI와 Tic-tac-toe 게임 플레이
 - play.py limited 1

선택되는 action의 quality 및 탐색 속도 비교 (v.s. Minimax)

• Alpha-beta pruning에도 적용 (with higher depth)


Evaluation Function Design

- Pacman (d = 2) with **simple** evaluation function
 - 두 칸 앞 까지 밖에 못 봄



Evaluation Function Design

- Pacman (d = 2) with **better** evaluation function
 - 추가 feature: Ghost와의 거리, Food와의 거리, 등등...



Parameterized Evaluation Function

• Feature vector: $\phi(s) \in \mathbb{R}^d$

$$\phi_1(s) = K - K'$$

$$\phi_1(s) = K - K'$$
 $\phi_2(s) = Q - Q'$


• Linear evaluation function

$$Eval(s; \mathbf{w}) = w \cdot \phi(s)$$

예.
$$w = [10^{100}, 9,5,3,1]$$


MAX agent

 $\phi(B) = [0,1,0,0,0]$ MIN opponent $Eval(B; \mathbf{w}) = 9$



5.5. Multi-player Game


Play Pacman!



- Play Pacman manually!
 - python pacman.py -1 smallClassic
- 화살표키로 이동

Pacman 게임 설정

- Pacman with multiple ghosts
 - a₀: Agent
 - a₁, ... a_n: 각각의 ghost
 - Multiple MIN layers (one for each ghost)
- 승리조건: 모든 food를 먹음
- 점수
 - 1프레임에 -1점
 - Food를 먹으면 +10점
 - 승리하면 +500점
 - 패배하면 -500점
- 패배조건: Ghost와 만남
- Capsule을 먹으면 일정 시간 동안 Ghost에 면역 (+200점)



Minimax and Expectimax

• Value function for multi-player minimax game


$$V_{\max,\min}(s,d) = \begin{cases} \text{Utility}(s) & \text{if IsEnd}(s) \\ \text{Eval}(s) & \text{if } d = 0 \\ \max_{a \in \text{Actions}(s)} V_{\max,\min}(\text{Succ}(s,a),d) & \text{if Player}(s) = a_0 \\ \min_{a \in \text{Actions}(s)} V_{\max,\min}(\text{Succ}(s,a),d) & \text{if Player}(s) = a_1 \dots, a_{n-1} \\ \min_{a \in \text{Actions}(s)} V_{\max,\min}(\text{Succ}(s,a),d-1) & \text{if Player}(s) = a_n \end{cases}$$

Value function for multi-player expectimax game

$$V_{\max, \text{opp}}(s, d) = \begin{cases} \text{Utility}(s) & \text{if IsEnd}(s) \\ \text{Eval}(s) & \text{if } d = 0 \end{cases}$$

$$V_{\max, \text{opp}}(s, d) = \begin{cases} \max_{a \in \text{Actions}(s)} V_{\max, \text{opp}}(\text{Succ}(s, a), d) & \text{if Player}(s) = a_0 \\ \sum_{a \in \text{Actions}(s)} \pi_{\text{opp}}(s, a) V_{\max, \text{opp}}(\text{Succ}(s, a), d) & \text{if Player}(s) = a_1 \dots, a_{n-1} \\ \sum_{a \in \text{Actions}(s)} \pi_{\text{opp}}(s, a) V_{\max, \text{opp}}(\text{Succ}(s, a), d - 1) & \text{if Player}(s) = a_n \end{cases}$$

Minimax and Expectimax



- 다음 turn에서 Pacman의 action은? west or east?
 - Minimax case
 - Expectimax case
- python pacman.py -p MinimaxAgent -l trappedClassic -a depth=3

- pacman.py
 - -p <Agent 타입>: ReflexAgent, MinimaxAgent, AlphaBetaAgent, ExpectimaxAgent
 - -l <Map 타입>: mediumClassic, openClassic
 - -a depth=<숫자>
 - 예. python pacman.py -p ReflexAgent -l mediumClassic
 - 예. python pacman.py -p MinimaxAgent -l mediumClassic -a depth=2
- submission.py
 - Agents
 - ReflexAgent
 - MinimaxAgent: minimax
 - AlphaBetaAgent: minimax + alpha-beta pruning
 - ExpectimaxAgent: expectimax
 - Agent의 getAction(gameState) 함수로 action 결정
 - 모든 agent는 기본적으로 depth-limited search

제공되는 변수 및 함수

- gameState.getLegalActions()
 - Returns the legal actions for the agent specified
 - Subset of [NORTH, SOUTH, EAST, WEST]
- gameState.generateSuccessor(agentIndex, action)
 - Returns the successor state after the specified agent takes the action
 - Pac-Man is always agent 0
- gameState.isWin() and gameState.isLose()
- gameState.getNumAgents()
 - Returns the total number of agents in the game
- gameState.getScore()
 - Returns the score corresponding to the current state of the game
- self.evaluationFunction(gameState)
 - Returns the game score of gameState
- self.index: Player index
- self.depth: Maximum depth

예. ReflexAgent

```
class ReflexAgent(Agent):
    def getAction(self, gameState):
        # Collect legal moves and successor states
        legalMoves = gameState.getLegalActions()

# Choose one of the best actions
        scores = [self.evaluationFunction(gameState, action) for action in legalMoves]
        bestScore = max(scores)
        bestIndices = [index for index in range(len(scores)) if scores[index] == bestScore]
        chosenIndex = random.choice(bestIndices) # Pick randomly among the best
        return legalMoves[chosenIndex]
```


• getAction 함수: gameState에서 최선의 action을 return

Multi-player Game 구현

- MinimaxAgent의 getAction 함수 구현
 - python pacman.py -p MinimaxAgent -l smallClassic
- AlphaBetaAgent의 getAction 함수 구현
 - python pacman.py -p AlphaBetaAgent -l smallClassic -a depth=3
- ExpectimaxAgent의 getAction 함수 구현
 - python pacman.py -p ExpectimaxAgent -l smallClassic

Pacman Competition

- Pacman (d = 2) with **better** evaluation function
 - 추가 feature: Ghost와의 거리, Food와의 거리, 등등...



 python pacman.py -1 smallClassic -p ExpectimaxAgent -a evalFn=better -q -n 20